



دانشگاه شهید بهشتی
Shahid Beheshti University

دانشکده علوم ریاضی

رشته علم داده‌ها

عنوان: خوشه‌بندی و پیش‌بینی درآمد سینمایی
بر پایه تحلیل اکتشافی داده‌ها

امین نمن الحسینی

بخش عملی

معرفی مجموعه داده

این مجموعه داده شامل اطلاعات جامعی درباره فیلم‌ها است که برای تحلیل‌های مختلف در حوزه داده‌کاوی مورد استفاده قرار می‌گیرد. این مجموعه داده، ویژگی‌های متنوعی از فیلم‌ها، از جمله جزئیات مالی، اطلاعات تولید، امتیازات کاربران و سایر مشخصات کلیدی را پوشش می‌دهد. با بررسی این داده‌ها، می‌توان به درک عمیق‌تری از عوامل تأثیرگذار بر موفقیت فیلم‌ها دست یافت و الگوهای پنهان در صنعت سینما را کشف کرد.

این مجموعه داده از اطلاعات فیلم‌ها به طور کلی شامل ۴۵۴۶۶ فیلم در ۲۴ ویژگی یا متغیر از فیلم‌ها است. می‌توان از منظر نوع متغیر این ۲۴ ویژگی را به دو نوع کیفی و کمی تقسیم کرد، در ادامه هریک به صورت خلاصه معرفی می‌شوند.

معرفی متغیرها

در این مجموعه داده ۱۷ متغیر از نوع کیفی و ۷ متغیر از نوع کمی هستند. می‌توان به کمک دو بخش زیر متغیرهای فیلم‌ها را به تفکیک ذکر شده مشاهده کرد.

الف) متغیرهای کیفی

متغیرهای کیفی به متغیرهایی گفته می‌شود که مقادیر آن‌ها به صورت دسته‌بندی یا ویژگی بیان می‌شود و به طور معمول ماهیت عددی ندارند. این متغیرها برای توصیف کیفیت‌ها یا گروه‌ها به کار می‌روند. به کمک جدول زیر اسامی متغیرهای کیفی، تعریف خلاصه شده‌ی آن‌ها و تعداد مقادیر گمشده در هر ویژگی کیفی آمده است.

متغیرهای کیفی	تعداد گمشدگی	تعریف
adult	صفر	آیا فیلم برای بزرگسالان است یا خیر؟
belongs_to_collection	۴۰۹۷۲	اطلاعات مربوط به مجموعه‌ای که فیلم به آن تعلق دارد.
genres	صفر	لیست ژانرهای مربوط به فیلم
homepage	۳۷۶۸۴	آدرس وب سایت رسمی فیلم
id	صفر	شناسه یکتا فیلم در پایگاه داده
imdb_id	۱۷	شناسه یکتا فیلم در پایگاه داده سایت

زبان اصلی که فیلم با آن ساخته شده است.	۱۱	original_language
عنوان اصلی فیلم	صفر	original_title
خلاصه داستان یا شرح کلی فیلم	۹۵۴	overview
مسیر دسترسی به تصویر پوستر رسمی فیلم	۳۸۶	poster_path
شرکت‌هایی که در فرآیند تولید فیلم مشارکت داشته‌اند.	۳	production_companies
کشورهایی که در فرآیند تولید فیلم مشارکت داشته‌اند.	۳	production_countries
لیست زبان‌هایی که در طول فیلم صحبت شده‌است.	۶	spoken_languages
وضعیت فعلی فیلم از منظر تولید	۸۷	status
جمله جذاب تبلیغاتی برای معرفی فیلم	۲۵۰۵۴	tagline
نام اصلی و تجاری فیلم	۶	title
آیا فیلم ویدئویی بوده‌است؟	۶	video

ب) متغیرهای کمی

متغیرهای کمی متغیرهایی هستند که مقادیر آن‌ها به صورت عددی بیان می‌شود و امکان انجام محاسبات ریاضی روی آن‌ها وجود دارد. این متغیرها مقدار یا اندازه یک ویژگی را نشان می‌دهند. به کمک جدول زیر اسامی متغیرهای کمی، تعریف خلاصه شده‌ی آن‌ها و تعداد مقادیر گمشده در هر ویژگی کمی آمده است.

تعریف	تعداد گمشدگی	متغیرهای کمی
بودجه ساخت فیلم بر اساس واحد دلار	صفر	budget
عددی که میزان محبوبیت فیلم را نشان می‌دهد.	۵	popularity
تاریخ دقیق انتشار فیلم	۸۷	release_date
میزان کل درآمد فیلم از فروش بر حسب دلار	۶	revenue
مدت زمان کل فیلم بر حسب دقیقه	۲۶۳	runtime

میانگین نمراتی است که کاربران به کیفیت فیلم داده‌اند.	۶	vote_average
تعداد کل افرادی که در امتیازدهی به فیلم شرکت کرده‌اند.	۶	vote_count

متغیر تاریخ انتشار به خودی خود یک متغیر کمی نیست، اما به دلیل اینکه از دل این متغیر سه متغیر مهم سال، ماه و روز انتشار حاصل می‌شود در این دسته قرار گرفته‌است.

می‌توان برای هر یک از متغیرهای کمی، آماره‌های توصیفی مقدماتی مانند میانگین، انحراف معیار و ... را بدست آورد. نتایجی از مقدار این آماره‌ها برای هر یک از متغیرها در جدول زیر برای درک بهتری از داده ارائه شده‌است.

نام متغیر	تعداد خطا	میانگین	انحراف معیار	مینیمم	چارک اول	میانه	چارک سوم	ماکسیمم
budget	۳	۴,۲۲۴,۵۷۹	۱۷,۴۲۴,۱۳۳	۰	۰	۰	۰	۳۸۰,۰۰۰,۰۰۰
popularity	۱	۲.۹۱	۶.۰۱	۰.۰۰	۰.۳۹	۱.۱۳	۳.۶۸	۵۴۷.۴۹
revenue	صفر	۱۱,۲۰۹,۳۴۹	۶۴,۳۳۲,۲۴۷	۰	۰	۰	۰	۲,۷۸۷,۹۶۵,۰۸۷
runtime	صفر	۹۴	۳۸	۰	۸۵	۹۵	۱۰۷	۱,۲۵۶
vote_avg	صفر	۵.۶۲	۱.۹۲	۰.۰۰	۵.۰۰	۶.۰۰	۶.۸۰	۱۰.۰۰
vote_count	صفر	۱۱۰	۴۹۱	۰	۳	۱۰	۳۴	۱۴,۰۷۵

با توجه به این موضوع که این آماره‌ها بدون پاکسازی داده به وجود آمده‌اند در همین ابتدا مشخص است که دو متغیر بودجه و درآمد دارای مقدار بسیار زیاد و تکراری صفر هستند که نمی‌توان آن را عادی برداشت کرد. می‌توان آن‌ها را به عنوان مقادیر گمشده در نظر گرفت ولی خب حجم بالای آن می‌تواند دردسرساز باشد.

در ادامه این پروژه سعی می‌شود تا این مجموعه داده نسبت به وجود مقادیر اشتباه و گمشده تمیز شود تا آماده برای مراحل بعدی مانند مدل‌سازی شود.

پاکسازی داده

به دلیل وجود حجم زیادی از انواع مختلف ایراد در این مجموعه داده، پاکسازی آن شامل مراحل مفصل و کاملی است که هر کدام در ادامه توضیح داده می‌شود.

گام یک: حذف متغیرهای ناکارآمد

در این گام چهار متغیر به عنوان ناکارآمد شناسایی می‌شوند، متغیرهای id و imdb_id به دلیل اینکه فقط به معنای یک شناسه یکتا در یک پایگاه داده هستند و ارزش تحلیلی ندارند. همچنین متغیر overview به این دلیل ناکارآمد است که توضیحاتی در خصوص فیلم است و بیشتر مناسب تحلیل متنی است که هدف این پژوهش نیست. و در انتها متغیر poster_path نیز به دلیل اینکه فقط دارای یک مسیر به پوستر فیلم است و شاید بیشتر مناسب تحلیل تصویری باشد جز متغیرهای ناکارآمد حساب می‌شود. در پایان تمام این چهار متغیر از این مجموعه داده حذف می‌شوند.

گام دو: تغییر مقادیر برخی متغیرها به وجود داشتن یا نداشتن

در گام دوم هدف متغیرهایی هستند که دارای بیشترین مقادیر گمشده در این مجموعه داده هستند. سه متغیر belongs_to_collection، homepage و tagline دارای بسیاری مقادیر خالی هستند و اهمیت آن‌ها بیشتر بودن یا نبودن آن‌ها است تا اینکه چه مقداری دارند. پس هر کدام از آن‌ها جایگزین یک ستون دودویی می‌شوند که سلول‌های دارای مقادیر به معنای وجود داشتن (یک) و مقادیر خالی یا گمشده به معنای وجود نداشتن (صفر) است.

گام سه: حذف ردیفی سایر داده‌ها با مقادیر گمشده

حال بعد از اصلاحات گام دو، تعداد فیلم‌ها با مقادیر گمشده به عدد ۴۲۳ فیلم در ۴۵۴۶۶ فیلم رسیده‌است. با توجه به این موضوع که نسبت این فیلم‌ها کمتر از یک درصد از کل است، این مشاهدات از مجموعه داده حذف می‌شوند تا دیگر مقداری به نام گمشدگی در هیچ جای داده قرار نداشته باشد و بتوان بعد از این گام وارد بخش‌های تغییراتی در مجموعه داده شد.

گام چهار: تغییر در متغیرهای چندرده‌ای

در این مجموعه داده چهار متغیر وجود دارد که هر سلول مقداری آن می‌تواند چندین رده را داشته باشد. به عنوان مثال یک فیلم می‌تواند همزمان چندین ژانر را دارا باشد. با توجه به میزان این رده‌ها برای هر متغیر می‌توان تصمیم گرفت. متغیر genres به دلیل اینکه تنها دارای ۲۰ رده است می‌توان ۲۰ ستون دودویی برای دارا بودن هر یک از رده‌ها در نظر گرفت.

اما سایر متغیرها یعنی متغیرهای production_countries ، production_companies و spoken_languages دارای بسیاری رده‌های مختلف هستند که حتی ممکن است تعداد آن‌ها به ۱۰۰۰ نیز برسد. در نتیجه از هر سلول از این متغیرها فقط رده‌ای که اول ذکر شده است به عنوان اهمیت بیشتر در نظر گرفته می‌شود. و همچنین از بین تمامی این رده‌های دارای اهمیت در همه‌ی مشاهدات، ده‌تایی که دارای بیشترین فراوانی هستند به صورت متغیرهای دودویی تعریف می‌شوند و در آخر متغیری هم به عنوان سایر تعریف می‌شود تا به تنهایی از این ۳ متغیر ۳۳ متغیر دودویی تولید شود.

گام پنج: تغییرات نهایی در متغیرهای باقیمانده

متغیر زمان انتشار به سه متغیر سال انتشار، ماه انتشار و روز انتشار تبدیل می‌شود تا خاصیت کمی پیدا کند و قابل بکارگیری در مدل‌های مختلف باشد. همچنین متغیر status به یک متغیر دودویی انتشار شدن یا نشدن تبدیل می‌شود زیرا اکثریت این مجموعه داده فیلم‌های منتشر شده است. همچنین متغیر original_language به دلیل اینکه یک متغیر تکراری با وجود متغیر spoken_languages است حذف می‌شود.

گام شش: اصلاح نوع حافظه متغیرها

در انتها، با توجه به وجود مدل‌های سنگین در این پژوهش در خصوص میزان حافظه هر متغیر مجدد اصلاحاتی جزئی انجام می‌شود تا این مجموعه داده به کارآمدترین حالت خود دست یابد.

گام هفت: وجود یک مشکل اساسی

بعد از پایان شش گام فوق بزرگترین مشکل در موضوعی است که پیش‌تر در بحث آماره توصیفی داده‌های کمی اشاره شد. دو متغیر revenue ، budget پراهمیت‌ترین متغیرهای این پژوهش هستند تا جایی که متغیر درآمد در اصل متغیر هدف این پژوهش است. اما از مقدار ۴۵۰۴۳ فیلم در این مجموعه داده اصلاح شده دارای به ترتیب ۳۶۱۷۰ و ۳۷۶۴۳ مقدار صفر هستند. وجود چنین نسبت بالایی از تکرار عدد صفر به شدت چالش‌زا است همچنین با وجود این موضوع که این متغیرها از اصلی‌ترین متغیرهای این پژوهش نیز هستند. در نتیجه در خصوص زمینه‌ی مدلسازی دو نوع مجموعه داده در نظر گرفته می‌شود: نوع اول مجموعه داده‌ای بدون وجود صفر در دو متغیر درآمد و بودجه که تعداد مشاهدات آن ۵۳۸۰ فیلم است. و نوع دوم: تمامی ۴۵۰۴۳ فیلم با وجود صفر در مشاهدات


تحلیل اکتشافی داده‌ها


به طور کلی می‌توان تحلیل اکتشافی داده‌ها را به سه بخش از منظر تعداد متغیر تفکیک کرد. همچنین این موضوع قابل ذکر است که طبق گام هفت پاکسازی داده ممکن است اصلاحاتی در خصوص متغیر در خصوص وجود صفر به معنای گمشدگی انجام شود.

تحلیل یک متغیره داده‌ها


می‌توان برای متغیرهای مهم و کمی این مجموعه داده به ترتیب نمودارهای جعبه‌ای و بافت‌نگاشت را رسم و از نظر وجود چولگی یا دور افتادگی در متغیرها هر یک را بررسی کرد.


متغیر بودجه یا budget به گونه‌ای بررسی شده‌است که ۳۶۱۷۰ سلول دارای مقادیر صفر دارد ولی در دو نمودار زیر در نظر گرفته نشده‌است. ولی باز هم به شدت دارای چولگی در راست توزیع است و نشان دهنده وجود فیلم‌هایی است که بودجه‌ی بسیار پرت و نجومی داشته‌اند. همچنین با توجه به نمودار جعبه‌ای مشخص است که تعداد این فیلم‌ها با بودجه‌های بسیار زیاد کم نبوده و تعداد آن‌ها هم قابل توجه است.







متغیر زمان فیلم یا runtime به گونه‌ای بررسی شده‌است که ۱۵۱۷ سلول دارای مقادیر صفر دارد ولی در دو نمودار زیر در نظر گرفته نشده‌است. با توجه به نمودارهای بافت نگاشت و جعبه‌ای این موضوع واضح است که اکثر فیلم‌ها مدت زمان حدودی ۱۰۰ دقیقه را دارا می‌باشند. هرچند که توزیع داده‌ها حول ۱۰۰ می‌باشد ولی از دو طرف نیز مقادیر دورافتاده‌ای وجود دارد که این مقادیر دور افتاده در سمت مثبت یعنی فیلم‌های طولانی تر شدید تر است.







متغیر میانگین نمره نظرات برای هر فیلم یا `vote_average` به گونه‌ای بررسی شده‌است که ۲۸۲۸ سلول دارای مقادیر صفر دارد ولی در دو نمودار زیر در نظر گرفته نشده‌است. با توجه به دو نمودار بافت نگاشت و جعبه‌ای مشخص است که توزیع داده‌ها بسیار شبیه به توزیع نرمال و دارای تقارن است. هرچند که در دو طرف مقادیر دور افتاده وجود دارد و در جهت منفی یعنی میانگین نظرات پایین این دورافتادگی کمی بیشتر است.







متغیر محبوبیت یا popularity دارای مقادیر دور افتاده‌ی به شدت عجیب و غیرعادی‌ای است اما امکان نادیده گرفتن این مشاهدات وجود ندارد. لازم به ذکر است که نمره ۴۲۰۲۶ فیلم از ۴۵۰۴۳ فیلم کمتر از ۱۰ بوده است. اما نمره بعضی فیلم‌ها به شدت بزرگ و عجیب نیز بوده تا جایی که به نمره ۵۰۰ نیز رسیده‌است. در هر صورت این متغیر به شدت چوله به راست و دارای مقادیر بسیار بزرگ و عجیب است که تعداد آن‌ها قابل چشم پوشی نیز نیست.





متغیر درآمد یا revenue به گونه‌ای بررسی شده‌است که ۳۷۶۴۳ سلول دارای مقادیر صفر دارد ولی در دو نمودار زیر در نظر گرفته نشده‌است. ولی باز هم به شدت دارای چولگی در راست توزیع است و نشان دهنده وجود فیلم‌هایی است که درآمد بسیار پرت و نجومی داشته‌اند. همچنین با توجه به نمودار جعبه‌ای مشخص است که تعداد این فیلم‌ها با درآمدهای بسیار زیاد کم نبوده و تعداد آن‌ها هم قابل توجه است.







تحلیل دو متغیره داده‌ها

در این قسمت دو نمودار پراکندگی مهم بررسی می‌شود و همچنین وجود رابطه از نوع خطی یا غیر خطی بین متغیرها نیز بحث می‌شود.

در خصوص بررسی رابطه بین دو متغیر بودجه یا budget و متغیر درآمد یا revenue، با توجه به حذف مقادیر صفر در دو متغیر وجود یک رابطه خطی مستقیم بین این دو متغیر به طور واضح مشخص است. در نتیجه می‌توان به طور تقریبی گفت فیلم‌هایی با بودجه و خرج زیاد دارای درآمد بیشتری نیز نسبت به سایر فیلم‌ها بوده‌اند.




همچنین در خصوص بررسی رابطه بین دو متغیر میانگین نمره نظرات یا `vote_average` و متغیر درآمد یا `revenue`، با توجه به حذف مقادیر صفر در دو متغیر وجود یک رابطه خطی مشاهده نمی‌شود اما برای بعضی مشاهدات رابطه بین این متغیر شبیه به وجود یک سهمی است که با افزایش میانگین نمره نظرات تا عدد ۷ رشد شدیدی دارد و سپس کاهشی می‌شود.




تحلیل چند متغیره داده‌ها

تحلیل متغیرهای کمی این مجموعه داده به کمک نمودار حرارتی یک گام خیلی مهم برای پی بردن به وجود رابطه خطی بین متغیرها است. این عمل برای هر دو مجموعه داده مشخص شده در گام هفت پاکسازی داده انجام می‌شود. یعنی یکبار برای کل داده و یکبار برای داده‌ها بدون وجود مقدار صفر در دو متغیر درآمد و بودجه انجام می‌شود.

در خصوص کل داده مشخص است که متغیر درآمد که متغیر هدف این پژوهش نیز است ارتباط خطی قوی‌ای با متغیرهای بودجه و تعداد نظرات به فیلم دارد. همچنین ارتباط به نسبت خوبی با متغیر محبوبیت فیلم دارد. نکته مهم و جالب این است که ارتباط قوی بین درآمد و بودجه حتی با وجود کلی صفر در هر دو متغیر همچنان حفظ شده که نشان دهنده این موضوع است که وجود صفر در این دو متغیر تصادفی نبوده است و به احتمال زیاد نبود اطلاعات باعث صفر شدن مقدار بودجه و درآمد به صورت همزمان شده است.



در مجموعه داده محدود نیز نتایج بسیار نزدیک است و نشان‌دهنده وجود ارتباط قوی بین درآمد و بودجه است. همچنین به جز متغیرهای بودجه، درآمد، محبوبیت و تعداد نظرات بقیه متغیرها ارتباط خطی خاصی باهم ندارند.



با توجه به وجود ارتباط بین صفرها در دو متغیر بودجه و درآمد مشاهداتی با وجود این مقادیر از مجموعه داده کنار گذاشته می‌شود و بر اساس ۵۳۸۰ اطلاع فیلمی که به صورت صحیح وارد شده است خوشه‌بندی و مدل شبکه عصبی اعمال می‌شود. زیرا وجود گمشدگی و مقدار نامعلوم به صورت غیر تصادفی قابل تحلیل نیست و اهمیت دو متغیر درآمد و بودجه بسیار زیاد است و کنار گذاشتن کلی این دو متغیر نیز امکان پذیر نیست.

خوشه بندی

در این بخش هدف گروه‌بندی فیلم‌ها بر اساس ویژگی‌های مشترک آن‌ها است تا بتوان الگوهای پنهان موجود در داده‌ها را شناسایی کرد. برای انجام این کار از سه متغیر کمی مهم شامل بودجه ساخت فیلم، مدت زمان فیلم و میانگین نمرات کاربران استفاده شده است. لازم به ذکر است که متغیر درآمد در فرآیند خوشه‌بندی استفاده نمی‌شود زیرا در مراحل بعدی به عنوان متغیر هدف برای پیش‌بینی به کار خواهد رفت.

همانطور که ذکر شد پیش از انجام خوشه‌بندی، فیلم‌هایی که دارای مقدار صفر در هر یک از دو متغیر بودجه و درآمد بودند حذف شدند تا نتایج خوشه‌بندی معنی‌دارتر باشند. وجود مقدار صفر در این متغیرها در بسیاری موارد به معنای نبود اطلاعات واقعی در داده‌ها است و می‌تواند باعث ایجاد خوشه‌های نادرست شود.

نرمالسازی ویژگی‌ها

از آنجا که متغیرهای مورد استفاده دارای مقیاس‌های بسیار متفاوتی هستند، قبل از اجرای الگوریتم خوشه‌بندی لازم است که مقادیر آن‌ها نرمال‌سازی شوند. برای مثال مقدار بودجه ممکن است در حد میلیون‌ها دلار باشد در حالی که میانگین نمره کاربران در بازه صفر تا ده قرار دارد. در صورت عدم نرمال‌سازی، متغیری که دارای مقیاس بزرگ‌تری است تأثیر بیشتری در محاسبه فاصله‌ها خواهد داشت.

برای حل این مشکل از روش استانداردسازی استفاده می‌شود. در این روش هر متغیر به گونه‌ای تبدیل می‌شود که دارای میانگین صفر و انحراف معیار یک باشد. این کار با استفاده از ابزار StandardScaler انجام می‌شود تا تمامی متغیرها نقش یکسانی در فرآیند خوشه‌بندی داشته باشند.

خوشه بندی با الگوریتم K-Means


در گام بعدی از الگوریتم K-Means برای خوشه‌بندی فیلم‌ها استفاده می‌شود. این الگوریتم یکی از رایج‌ترین روش‌های خوشه‌بندی است که داده‌ها را به K گروه تقسیم می‌کند به گونه‌ای که فاصله هر داده تا مرکز خوشه

خود حداقل باشد. برای تعیین تعداد مناسب خوشه‌ها، الگوریتم K-Means برای مقادیر مختلف K از ۲ تا ۱۰ اجرا می‌شود و برای هر مقدار K دو معیار مختلف محاسبه می‌شود:

۱- مقدار **Inertia** که مجموع مربعات فاصله داده‌ها از مرکز خوشه مربوط به خود است.

۲- مقدار **Silhouette Score** که میزان کیفیت تفکیک خوشه‌ها را اندازه‌گیری می‌کند.

نتایج این دو معیار در قالب نموداری بر حسب تعداد خوشه‌ها رسم می‌شود. در نمودار **Inertia** نقطه‌ای جذاب است که کاهش مقدار این معیار پس از آن چندان قابل توجه نباشد که به آن روش آرنج Elbow Method گفته می‌شود. از طرف دیگر مقدار **Silhouette Score** هرچه بزرگ‌تر باشد نشان‌دهنده کیفیت بهتر خوشه‌بندی است. با توجه به نمودار زیر مشخص است که بهترین نقطه که همزمان در دو معیار نتیجه خوبی داشته باشد در نقطه $k = 5$ است.




خوشه‌بندی سلسله مراتبی

علاوه بر الگوریتم K-Means، از روش خوشه‌بندی سلسله مراتبی Hierarchical Clustering نیز برای بررسی ساختار داده‌ها استفاده می‌شود. در این روش از الگوریتم Agglomerative استفاده شده است که در ابتدا هر مشاهده را به عنوان یک خوشه مستقل در نظر می‌گیرد و سپس به تدریج نزدیک‌ترین خوشه‌ها را با یکدیگر ادغام می‌کند.

از آنجا که این روش به طور مستقیم مقدار *Inertia* را ارائه نمی‌دهد، برای هر مقدار k یک مدل *K-Means* جداگانه اجرا می‌شود تا مقدار *Inertia* محاسبه شود. در مقابل، مقدار *Silhouette Score* مستقیماً از نتایج خوشه‌بندی سلسله‌مراتبی به دست می‌آید.

همانند بخش قبل، برای مقادیر مختلف k از ۲ تا ۱۰ این معیارها محاسبه و نمودارهای مربوطه رسم می‌شود. نتایج نشان می‌دهد که تعداد خوشه‌های مناسب در این روش نیز مشابه نتایج به دست آمده از الگوریتم *K-Means* است و ساختار کلی داده‌ها را به خوبی تأیید می‌کند.



تخصیص برچسب خوشه‌ها

پس از انتخاب تعداد بهینه خوشه‌ها به کمک دو الگوریتم بالا، مجدد الگوریتم *K-Means* با مقدار $k = 5$ بر روی داده‌ها اجرا می‌شود و برای هر فیلم یک برچسب خوشه اختصاص داده می‌شود. این برچسب‌ها به عنوان یک متغیر جدید به مجموعه داده افزوده می‌شوند تا در مراحل بعدی تحلیل و مدل‌سازی مورد استفاده قرار گیرند.

به منظور استفاده بهتر از این اطلاعات در مدل شبکه عصبی، برچسب‌های خوشه به صورت متغیرهای دودویی (*One-Hot Encoding*) تبدیل می‌شوند. به این ترتیب برای هر خوشه یک ستون جداگانه ایجاد می‌شود که نشان می‌دهد هر فیلم متعلق به کدام خوشه است.

شبکه عصبی برای پیش‌بینی درآمد فیلم

در بخش پایانی این پژوهش هدف پیش‌بینی میزان درآمد فیلم‌ها با استفاده از ویژگی‌های موجود در مجموعه داده است. برای این منظور از یک مدل شبکه عصبی مصنوعی استفاده شده‌است که قادر است روابط پیچیده و غیرخطی میان متغیرها را یاد بگیرد.

تقسیم داده‌ها

برای آموزش و ارزیابی مدل، مجموعه داده به سه بخش تقسیم می‌شود. ۷۰ درصد از داده‌ها به عنوان مجموعه آموزش برای یادگیری مدل استفاده می‌شوند. ۱۵ درصد از داده‌ها به عنوان مجموعه اعتبارسنجی برای پایش عملکرد مدل در حین آموزش مورد استفاده قرار می‌گیرند و ۱۵ درصد باقی‌مانده به عنوان مجموعه آزمون برای ارزیابی نهایی مدل در نظر گرفته می‌شود.

نرمال سازی ویژگی‌ها

پیش از آموزش شبکه عصبی، تمامی ویژگی‌های ورودی با استفاده از روش StandardScaler نرمال سازی می‌شوند. نکته مهم این است که پارامترهای نرمال سازی تنها بر اساس داده‌های مجموعه آموزش محاسبه می‌شوند و سپس همان تبدیل بر روی داده‌های اعتبارسنجی و آزمون اعمال می‌شود تا از نشت اطلاعات جلوگیری شود. همچنین برای بهبود همگرایی مدل، متغیر هدف یعنی درآمد فیلم نیز استانداردسازی می‌شود و پس از انجام پیش‌بینی‌ها مقادیر آن به مقیاس اصلی بازگردانده می‌شود.

معماری شبکه عصبی

مدل مورد استفاده از نوع شبکه عصبی با اتصال کامل است که شامل یک لایه ورودی، دو لایه پنهان و یک لایه خروجی می‌باشد. در لایه پنهان اول ۶۴ نورون با تابع فعال سازی ReLU قرار داده می‌شود. لایه پنهان دوم شامل ۳۲ نورون با همان تابع فعال سازی است. در نهایت لایه خروجی شامل یک نورون با تابع فعال سازی خطی است که مقدار درآمد پیش‌بینی شده را تولید می‌کند.

برای آموزش مدل از تابع خطای میانگین مربعات Mean Squared Error استفاده می‌شود و الگوریتم بهینه سازی Adam وظیفه بروزرسانی وزن‌های شبکه را بر عهده خواهد داشت. آموزش مدل در ۳۰ دوره (Epoch) و با اندازه ۳۲ دسته انجام می‌شود.

ارزیابی مدل

پس از پایان فرآیند آموزش، عملکرد مدل بر روی مجموعه آزمون که در طول آموزش مشاهده نشده بود ارزیابی می‌شود. برای سنجش کیفیت پیش‌بینی‌ها از دو معیار اصلی استفاده می‌شود.

۱- خطای میانگین مربعات (MSE) است که میانگین مربع اختلاف بین مقادیر واقعی و پیش‌بینی شده را اندازه‌گیری می‌کند.

۲- ضریب تعیین (R^2) است که نشان می‌دهد چه نسبتی از تغییرات متغیر هدف توسط مدل توضیح داده می‌شود.

نتایج نشان می‌دهد که مقدار ضریب تعیین مدل برای داده‌های آزمون برابر با حدود ۰.۷۱ است. این مقدار نشان می‌دهد که مدل شبکه عصبی قادر است بخش قابل توجهی از تغییرات درآمد فیلم‌ها را بر اساس ویژگی‌های موجود در داده‌ها توضیح دهد و عملکرد به نسبت مناسبی در پیش‌بینی درآمد فیلم‌ها داشته است.